

Aplicación de modelos de inteligencia artificial para monitorización del paciente crítico.

José Pablo Fernández Magaña, residente de tercer año Urgencias Médico Quirúrgicas. Hospital General Dr. Manuel Gea González. Elaborado para el Primer Simposio Innovación y Buenas Prácticas en Medicina Crítica (COMECEQ). Septiembre de 2025.

Resumen

La medicina crítica se caracteriza por la complejidad y la variabilidad extrema de los pacientes en estado crítico, lo que convierte su evolución clínica en un sistema dinámico y caótico, comparable al comportamiento del clima. La inteligencia artificial (IA), mediante técnicas como redes neuronales, aprendizaje automático y visión por computador, ha mostrado un gran potencial para analizar interacciones no lineales y detectar tempranamente el deterioro clínico. En esta revisión se exploran las aplicaciones actuales de la IA en la monitorización del paciente crítico, desde la predicción de lesión renal aguda y fracaso de extubación, hasta la detección de asincronías ventilatorias y la implementación de sensores electrónicos para diuresis. Además, se discute el uso de modelos de aprendizaje federado y tecnologías innovadoras como el reconocimiento óptico de caracteres para digitalización de monitores, así como la fotopletismografía remota. Se plantea que la IA puede convertirse en una herramienta fundamental para la vigilancia continua, permitiendo anticipar complicaciones y optimizar la toma de decisiones en terapia intensiva.

Palabras clave: *inteligencia artificial, cuidados críticos, monitorización, machine learning, deep learning.*

1. Introducción

El paciente crítico representa un desafío constante por la naturaleza impredecible de su evolución clínica. Las alteraciones fisiológicas en este contexto no siguen patrones lineales, sino que se comportan como sistemas dinámicos complejos, donde pequeñas variaciones en un parámetro pueden desencadenar consecuencias desproporcionadas en otros. Este fenómeno, comparable a la teoría del caos aplicada al clima, implica que la predicción y el monitoreo del estado del enfermo crítico requieren estrategias capaces de reconocer interacciones ocultas y no lineales.

La inteligencia artificial (IA), particularmente a través de modelos de aprendizaje automático (machine learning) y aprendizaje profundo (deep learning), ha emergido como una herramienta prometedora para enfrentar este reto. Estos modelos permiten analizar grandes volúmenes de datos fisiológicos, integrando información de monitores, ventiladores, laboratorios y expedientes clínicos electrónicos para generar predicciones en tiempo real.

2. Los sistemas caóticos y la utilidad de la IA

Los sistemas caóticos, como el clima o el organismo humano en estado crítico, se caracterizan por una alta sensibilidad a las condiciones iniciales y por la dificultad de predecir su comportamiento a largo plazo. Sin embargo, dentro de este aparente desorden existen patrones que pueden ser identificados mediante algoritmos de IA. Al igual que los

modelos meteorológicos se han beneficiado del análisis computacional avanzado para pronosticar tormentas o cambios de temperatura, la monitorización clínica puede apoyarse en estas técnicas para anticipar deterioros, insuficiencia orgánica o eventos adversos antes de que sean evidentes en la exploración clínica.

3. Aplicaciones actuales de la inteligencia artificial en medicina crítica

3.1 Predicción de lesión renal aguda

El grupo de Tomašev et al. analizó más de 700,000 pacientes del sistema Veterans Affairs en EUA, incluyendo miles de estancias en unidades de cuidados intensivos (UCI) [1]. Utilizaron un modelo de deep learning basado en redes neuronales recurrentes (RNN, por sus siglas en inglés) que integraba más de 600 variables de registros electrónicos: creatinina sérica seriada, balance hídrico, fármacos nefrotóxicos, constantes vitales, biometría hemática y comorbilidades. El modelo generaba una predicción horaria de riesgo de lesión renal aguda (acute kidney injury, AKI), logrando un área bajo la curva de la característica operativa del receptor (AUROC, por sus siglas en inglés) de 0.921 para la detección de AKI a 48 h. Entre las variables con mayor peso estuvieron la tendencia de creatinina en las 48 h previas, la variación de presión arterial media y la presencia de antibióticos aminoglucósidos. Un aspecto innovador fue la incorporación de saliency maps para identificar qué secuencias de datos activaban la predicción, aportando interpretabilidad.

3.2 Estrategias de tratamiento de sepsis

Komorowski et al. entrenaron el Artificial Intelligence Clinician con más de 17,000 pacientes con sepsis en la base MIMIC-III y validaron en 20,000 pacientes de eICU [2]. Emplearon un modelo de aprendizaje por refuerzo profundo (deep reinforcement learning) mediante Deep Q-learning para aprender políticas óptimas en la administración de fluidos y vasopresores. La inteligencia artificial (IA) no se limitó a predecir mortalidad, sino que exploró diferentes combinaciones de intervenciones y estimó su impacto en la supervivencia. Un hallazgo clave fue que el algoritmo tendía a recomendar menores volúmenes acumulados de líquidos y titulación más temprana de vasopresores, en comparación con las prácticas clínicas observadas. En la validación externa, la supervivencia fue significativamente mayor cuando las decisiones médicas coincidieron con las recomendaciones del algoritmo. Esto sugiere que la IA identificó un equilibrio óptimo entre resucitación hídrica y soporte vasopresor que podría pasar desapercibido en la práctica habitual.

3.3 Predicción de fracaso de extubación

En el estudio de Zhao et al. participaron 4,083 pacientes ventilados mecánicamente de 12 UCI en China [3]. Se entrenaron modelos de random forest, gradient boosting y redes neuronales artificiales (ANN, por sus siglas en inglés) con un conjunto de más de 90 variables, incluyendo edad, índice de comorbilidades, escala APACHE II, duración de la ventilación, presión de soporte, volumen tidal, presión positiva al final de la espiración (PEEP), índice de oxigenación ($\text{PaO}_2/\text{FiO}_2$), frecuencia respiratoria, relación f/VT (índice de Tobin) y pH arterial. El random forest identificó como predictores más importantes el índice f/VT, la relación $\text{PaO}_2/\text{FiO}_2$, la duración de la ventilación mecánica y la albúmina sérica. El AUROC del modelo superó 0.85, significativamente mayor al de los criterios clínicos convencionales, demostrando que la IA puede capturar interacciones no lineales entre parámetros respiratorios y estado general del paciente.

3.4 Detección de asincronías paciente-ventilador

Rietveld et al. recopilaron 19 estudios con más de 1,200 pacientes ventilados y bases de datos de decenas de miles de ciclos respiratorios [4]. Entre los algoritmos empleados destacan redes neuronales convolucionales (CNN, por sus siglas en inglés) aplicadas a curvas de presión y flujo, así como ensambles de support vector machines (SVM). Una de las aplicaciones más robustas alcanzó una exactitud superior al 95% en la detección de esfuerzos ineficaces y double-triggering. La variable más influyente en los modelos fue la morfología del flujo espiratorio, seguida de la relación presión-tiempo en la fase inspiratoria. Prototipos en tiempo real, como el sistema SmartAlert [5], utilizan CNN embebidas en microcontroladores conectados al ventilador, logrando clasificación en milisegundos. Estos avances podrían traducirse en reducción de sedación y tiempos de ventilación.

3.5 Sistemas de alerta temprana potenciados por IA

Salehinejad et al. compararon modelos de aprendizaje automático con el National Early Warning Score 2 (NEWS2) en más de 60,000 hospitalizaciones [6]. Usaron algoritmos basados en redes de memoria a largo corto plazo (LSTM, por sus siglas en inglés) que procesaban secuencias completas de signos vitales (presión arterial, frecuencia cardíaca, temperatura, frecuencia respiratoria, saturación de oxígeno por pulsioximetría). El modelo alcanzó un AUROC de 0.87 para deterioro clínico (paro cardiorrespiratorio o ingreso a UCI), frente a 0.74 del NEWS2. Una fortaleza fue que el modelo ponderó dinámicamente la velocidad de cambio de las constantes, más que los valores absolutos, demostrando que la dinámica temporal es un predictor más potente que los umbrales fijos.

3.6 Monitorización no invasiva mediante visión por computador

Diao et al. probaron sistemas de fotoplethysmografía remota (remote photoplethysmography, rPPG) en pacientes posquirúrgicos monitorizados en UCI [7]. Cámaras RGB capturaban microvariaciones de color facial, traducidas en curvas de pulso. Los algoritmos basados en independent component analysis (ICA) y CNN lograron un error absoluto medio de 2.5 latidos por minuto para la frecuencia cardíaca y 2.4 respiraciones por minuto para la frecuencia respiratoria, en comparación con monitores de referencia. Sin embargo, la disponibilidad de señal fue limitada por movimiento y condiciones de luz (alrededor de 50% del tiempo utilizable). Revisiones recientes [8] destacan que la IA puede mitigar estos problemas mediante algoritmos de reconstrucción de señal y calibración individualizada, lo que perfila estas técnicas como complementarias a la monitorización estándar.

3.7 Reconocimiento óptico de caracteres para digitalización de monitores

El sistema ROMI (Real-time Optical digit recognition for Monitoring in ICU) fue desarrollado por Jeon et al. [9]. Consistía en una cámara embebida en hardware Jetson que capturaba la pantalla de los monitores y ventiladores, aplicando CNN para reconocimiento de dígitos. Alcanzó un AUROC de 0.989, con tiempos de procesamiento compatibles con monitorización en tiempo real. Esta tecnología es especialmente relevante en entornos donde los equipos no cuentan con puertos de exportación de datos, ofreciendo una alternativa económica para integrar la información al expediente digital.

3.8 Monitorización electrónica de la diuresis

Minor et al. compararon la monitorización manual frente a sensores electrónicos de orina en pacientes de UCI [10]. La medición manual mostró un sesgo de 19.9 ml/h y retrasos de

hasta 6 h en el registro. Los sensores electrónicos no presentaron diferencias significativas respecto al patrón oro y detectaron episodios de oliguria no identificados manualmente. En estudios posteriores, la monitorización electrónica de diuresis se asoció con mayor detección temprana de AKI y reducción en estancia en UCI [11,12]. Estos hallazgos confirman que la integración de sensores con algoritmos predictivos puede mejorar sustancialmente la vigilancia renal.

3.9 Aprendizaje federado multicéntrico

Huang et al. desarrollaron un modelo de aprendizaje federado (federated learning) de predicción de AKI en cinco hospitales de Taiwán [13]. Se entrenaron algoritmos de random forest, XGBoost y ANN en cada institución, compartiendo únicamente los parámetros entrenados, no los datos crudos. El modelo federado superó en AUROC a los modelos locales (0.81 vs 0.75), demostrando que la IA puede beneficiarse de la heterogeneidad de los datos multicéntricos sin vulnerar la privacidad de los pacientes. Este enfoque es particularmente prometedor en cuidados críticos, donde las cohortes únicas son insuficientes para la generalización.

4. Perspectivas futuras: dispositivos avanzados de monitorización

El futuro de la monitorización en cuidados intensivos apunta hacia dispositivos híbridos que integren múltiples fuentes de datos y empleen IA en tiempo real. Ejemplos incluyen: Cámaras con visión por computador y reconocimiento óptico de caracteres (OCR, por sus siglas en inglés) para digitalizar pantallas de monitores, ventiladores y bombas de infusión. Sensores de peso conectados a algoritmos predictivos para cuantificar diuresis minuto a minuto y detectar precozmente la instalación de AKI.

Estas tecnologías, combinadas con arquitecturas de aprendizaje federado, podrían permitir la creación de modelos globales que se nutran de datos multicéntricos sin comprometer la privacidad. A largo plazo, la meta es un sistema de “monitorización inteligente” que no solo alerte sobre valores anormales, sino que contextualice su significado clínico y sugiera intervenciones personalizadas.

5. Conclusiones

La IA se ha consolidado como una herramienta de gran valor en la medicina crítica, ofreciendo la posibilidad de anticipar eventos adversos y optimizar la toma de decisiones. La predicción de lesión renal aguda, el manejo de la sepsis, la detección de asincronías ventilatorias y la monitorización electrónica de la diuresis son ejemplos concretos donde su aplicación ha demostrado beneficios. La incorporación de tecnologías como visión por computador, OCR y aprendizaje federado anticipa un futuro en el que la monitorización será más precisa, continua y contextualizada.

La evolución del paciente crítico es un sistema caótico, pero la IA abre la posibilidad de identificar patrones ocultos en ese caos, transformando la práctica clínica hacia un modelo proactivo y preventivo.

6. Referencias

- [1] Tomašev N, Glorot X, Rae JW, et al. A clinically applicable approach to continuous prediction of future acute kidney injury. *Nature*. 2019;572(7767):116-119. doi:10.1038/s41586-019-1390-1.
- [2] Komorowski M, Celi LA, Badawi O, Gordon AC, Faisal AA. The Artificial Intelligence Clinician learns optimal treatment strategies for sepsis in intensive care. *Nat Med*. 2018;24(11):1716-1720. doi:10.1038/s41591-018-0213-5.
- [3] Zhao QY, Liu LP, Luo JC, et al. Development and Validation of a Machine-Learning Model for Prediction of Extubation Failure in ICUs. *Front Med (Lausanne)*. 2021;8:676343. doi:10.3389/fmed.2021.676343.
- [4] Rietveld TP, van Veenendaal N, Smit JM, et al. Let's get in sync: current standing and future of AI-based detection of patient-ventilator asynchrony. *Intensive Care Med Exp*. 2025;13:in press. doi:10.1186/s40635-025-00746-8.
- [5] Pažout J, Kolařík M, Ždánký J, et al. SmartAlert: Machine learning-based patient-ventilator asynchrony detection in real-time. *Comput Methods Programs Biomed*. 2025;Epub ahead of print. doi:10.1016/S0169-2607(25)00344-X.
- [6] Salehinejad H, Bamdad M, Mahjoob MP, et al. Novel machine learning model to improve performance of an early warning system in hospitalized patients: a retrospective multisite cross-validation study. *eClinicalMedicine*. 2023;66:102312. doi:10.1016/j.eclinm.2023.102312.
- [7] Diao JA, Marwaha JS, Kvedar JC. Video-based physiologic monitoring: promising applications for the ICU and beyond. *NPJ Digit Med*. 2022;5(1):26. doi:10.1038/s41746-022-00575-z.
- [8] Huang B, Hu S, Liu Z, et al. Challenges and prospects of visual contactless physiological monitoring in clinical study. *NPJ Digit Med*. 2023;6:231. doi:10.1038/s41746-023-00973-x.
- [9] Jeon S, Ko BS, Son SH. ROMI: A Real-Time Optical Digit Recognition Embedded System for Monitoring Patients in Intensive Care Units. *Sensors (Basel)*. 2023;23(2):638. doi:10.3390/s23020638.
- [10] Minor J, Smith A, Deutsch F, Kellum JA. Automated versus manual urine output monitoring in the intensive care unit. *Sci Rep*. 2021;11(1):17429. doi:10.1038/s41598-021-97026-8.
- [11] Murad O, Orjuela Cruz DF, van Heerden PV. Improving awareness of kidney function through electronic urine output monitoring: a comparative study. *BMC Nephrol*. 2022;23(1):412. doi:10.1186/s12882-022-03046-5.
- [12] Willner D, Ustun B, Beale AL, et al. Early identification of acute kidney injury in the ICU with real-time urine output monitoring: a clinical investigation. *Crit Care Explor*. 2021;3(8):e0521. doi:10.1097/CCE.0000000000000521.
- [13] Huang CT, Wang TJ, Kuo LK, et al. Federated machine learning for predicting acute kidney injury in critically ill patients: a multicenter study in Taiwan. *Health Inf Sci Syst*. 2023;11(1):48. doi:10.1007/s13755-023-00248-5.

Contacto:

José Pablo Fernández Magaña

drpablo.hospital@gmail.com

442-302-2655